[ENCG SETTAT]

[Cours / Module : BASE DE DONNEE ET DATA SCIENCE]

Introduction à l'apprentissage automatique appliquée au risque de crédit

Étude du jeu de données *German Credit*

Rapport de travaux pratiques

Auteur(s) : [MOUKRIM ISRAE ET LINA MIZEB]

Encadrant : [ABDERRAHIM LARHILMI]

Année universitaire : [2026–2027]

6 novembre 2026

Résumé

Ce rapport présente une étude d'apprentissage supervisé appliquée à la prédiction du risque de crédit à partir du jeu de données *Statlog (German Credit Data)*, qui décrit 1 000 demandes de crédit dont 30 % de mauvais risques. Après une exploration des données et un prétraitement sans fuite d'information, quatre modèles sont comparés par validation croisée : une référence naïve, une régression logistique, un arbre de décision et une forêt aléatoire. Le meilleur modèle atteint une AUC de [0,xx] sur le jeu de test. Le problème présentant des coûts d'erreur asymétriques (accepter un mauvais payeur coûte cinq fois plus que refuser un bon client), le seuil de décision est choisi en minimisant le coût moyen et non en maximisant l'exactitude : le coût moyen par dossier passe de [x,xx] (seuil 0,5) à [x,xx] (seuil optimal [0,xx]). Une analyse de sensibilité, une interprétation du modèle et une discussion éthique complètent l'étude.

Table des matières

1 Introduction **3**

2 Type d'apprentissage **3**

3 Données **4**

3.1 Présentation du jeu de données 4

3.2 Matrice de coûts 4

4 Exploration des données **4**

4.1 Statistiques descriptives 5

4.2 Répartition des classes 5

4.3 Variables numériques 5

4.4 Variables catégorielles 6

4.5 Corrélations 6

5 Préparation des données **6**

6 Comparaison des modèles **7**

6.1 Modèles et métriques 7

6.2 Résultats 7

7 Évaluation sur le jeu de test **8**

7.1 Matrice de confusion au seuil de 0,5 8

7.2 Courbes ROC 8

7.3 Courbe d'apprentissage 9

8 Choix du seuil de décision **9**

8.1 Coût moyen et seuil optimal 9

8.2 Comparaison des stratégies 10

8.3 Analyse de sensibilité à la matrice de coûts 10

9 Interprétation du modèle **11**
9.1 Importance des variables (forêt aléatoire) 11
9.2 Coefficients de la régression logistique 11
9.3 Exemple de prédiction 12

10 Discussion : éthique et limites **12**

11 Conclusion **12**

A Réponses aux questions du TP **13**

B Code utilisé **13**

1 Introduction

Les établissements de crédit doivent décider, pour chaque demande, d'accorder ou de refuser un prêt. Une erreur de décision a un coût : accorder un prêt à un client qui ne le remboursera pas engendre une perte, tandis que refuser un bon client représente un manque à gagner. L'apprentissage automatique permet d'estimer, à partir des caractéristiques du client et du prêt, la probabilité de défaut.

Problématique. Comment construire et évaluer un modèle de prédiction du risque de crédit lorsque les classes sont déséquilibrées et que les erreurs n'ont pas le même coût ?

Objectifs. Ce travail vise à :

1. identifier le type d'apprentissage et justifier ce choix ;
2. explorer et préparer les données sans fuite d'information ;
3. comparer plusieurs modèles de classification à une référence simple ;
4. évaluer le modèle retenu (matrice de confusion, courbe ROC, courbe d'apprentissage) ;
5. traduire les erreurs en coûts financiers et choisir un seuil de décision ;
6. interpréter le modèle et en discuter les limites.

Plan. La section 2 identifie le type d'apprentissage, la section 3 présente les données, la section 4 les explore, la section 5 décrit la préparation, et les sections 6 à 9 présentent les modèles, leur évaluation et leur interprétation. Les limites et la conclusion terminent le rapport.

2 Type d'apprentissage

Le problème consiste à prédire, à partir des caractéristiques d'un client et de son prêt, s'il s'agit d'un bon ou d'un mauvais risque de crédit. Il relève de l'**apprentissage supervisé**, plus précisément de la **classification binaire**, pour trois raisons :

— **supervisé** : chaque dossier est associé à une étiquette connue (l'issue du prêt est observée a posteriori) ; le modèle apprend à partir de paires (entrée, sortie) ;
— **classification binaire** : la cible ne prend que deux valeurs (si la cible était le montant du prêt, il s'agirait d'une régression) ;
— **à coûts asymétriques** : toutes les erreurs ne se valent pas, ce qui rend l'exactitude insuffisante comme critère de choix.

Un algorithme non supervisé (par exemple un partitionnement) ne recevrait pas l'étiquette et chercherait seulement des groupes de clients similaires.

3 Données

3.1 Présentation du jeu de données

Le jeu de données *Statlog (German Credit Data)* [1] est hébergé par le dépôt UCI Machine Learning Repository (identifiant 144). Il décrit **1 000 demandes de crédit** d'une banque allemande, avec **20 variables** explicatives (7 numériques et 13 catégorielles) et une cible : 700 bons risques et 300 mauvais risques. Aucune valeur manquante n'est présente. Le chargement s'effectue directement depuis OpenML (`credit-g`), avec un repli sur l'archive UCI officielle.

Table 1 – Principales variables du jeu de données.

Variable	Type	Description
`class` (cible)	catégorielle	bon risque (*good*) ou mauvais risque (*bad*)
`checking_status`	catégorielle	situation du compte courant
`duration`	numérique	durée du crédit (mois)
`credit_history`	catégorielle	historique de crédit
`purpose`	catégorielle	motif du crédit
`credit_amount`	numérique	montant du crédit
`savings_status`	catégorielle	épargne
`employment`	catégorielle	ancienneté dans l'emploi actuel
`installment_commitment`	numérique	taux de remboursement (% du revenu disponible)
`personal_status`	catégorielle	situation personnelle (sexe et état civil)
`age`	numérique	âge (années)
`housing`	catégorielle	logement (propriétaire, locataire, gratuit)
`foreign_worker`	catégorielle	travailleur étranger
		...

3.2 Matrice de coûts

La documentation du jeu de données propose la matrice de coûts du tableau 2. Accepter un mauvais risque coûte cinq fois plus que refuser un bon client. Ces coûts sont des *hypothèses* : une analyse de sensibilité est menée à la section 8.3.

Table 2 – Matrice de coûts (en unités relatives).

	Prédit : accepter	**Prédit : refuser**
Réel : bon risque	0	1 (client perdu)
Réel : mauvais risque	5 (prêt non remboursé)	0

4 Exploration des données

On crée la cible numérique `mauvais_risque` (1 pour un mauvais risque, 0 sinon). Le mauvais risque est la classe « positive », c'est-à-dire l'événement que la banque cherche à détecter.

4.1 Statistiques descriptives

Table 3 – Statistiques descriptives des variables numériques.

Variable	Moyenne	Écart-type	Min	Médiane	Max
duration	[–]	[–]	[–]	[–]	[–]
credit_amount	[–]	[–]	[–]	[–]	[–]
installment_commitment	[–]	[–]	[–]	[–]	[–]
residence_since	[–]	[–]	[–]	[–]	[–]
age	[–]	[–]	[–]	[–]	[–]
existing_credits	[–]	[–]	[–]	[–]	[–]
num_dependents	[–]	[–]	[–]	[–]	[–]

Le jeu de données est complet. Les unités sont très hétérogènes (montant en milliers, durée en dizaines de mois, plusieurs variables prenant seulement les valeurs 1 à 4), ce qui justifie une mise à l'échelle pour les modèles sensibles à l'amplitude des variables. La moyenne du montant dépasse nettement sa médiane : la distribution est asymétrique à droite.

4.2 Répartition des classes

Figure manquante : `figures/figclasses.pdf`

Figure 1 – Nombre de dossiers par classe.

Les classes sont déséquilibrées : 700 bons risques contre 300 mauvais (figure 1). Un classifieur qui prédit toujours « bon risque » obtient donc 70 % d'exactitude sans rien apprendre. Nous utilisons par conséquent une validation stratifiée et évaluons les modèles avec l'AUC et le coût, et pas seulement l'exactitude.

4.3 Variables numériques

Figure manquante : `figures/figdistributions.pdf`

Figure 2 – Distribution des variables numériques selon le risque.

Les mauvais payeurs empruntent plutôt plus longtemps, pour des montants plus élevés, et sont un peu plus jeunes (figure 2). Les distributions se chevauchent toutefois largement : aucune variable numérique ne suffit à elle seule, et le problème est intrinsèquement bruité.

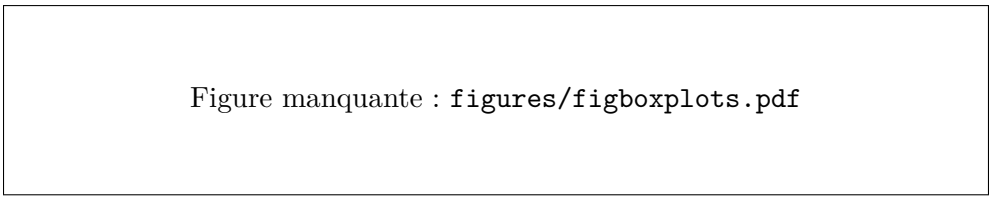


Figure 3 – Boîtes à moustaches par classe (échelle logarithmique pour le montant).

4.4 Variables catégorielles

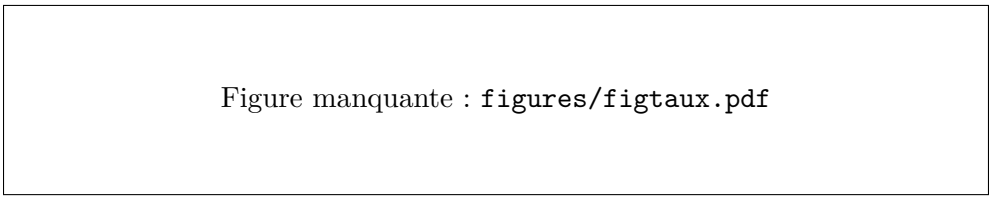


Figure 4 – Taux de mauvais risque par modalité (pointillé : taux global de 30 %).

La situation du compte courant est très discriminante : les clients sans compte ou avec un solde confortable présentent un taux de défaut nettement inférieur au taux global, les clients à compte négatif un taux nettement supérieur (figure 4). L'historique de crédit et l'épargne vont dans le même sens.

4.5 Corrélations

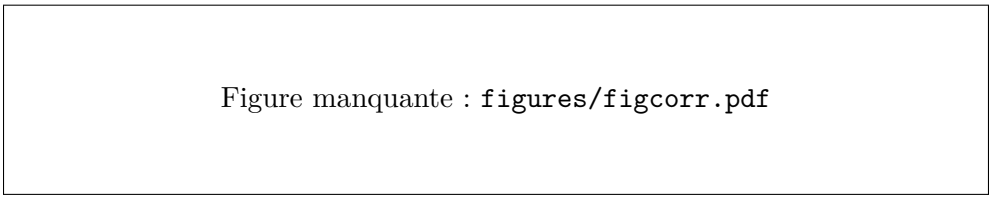


Figure 5 – Matrice de corrélation des variables numériques et de la cible.

La durée et le montant du crédit sont corrélés entre eux (figure 5) et partagent une partie de leur information. Leurs corrélations avec la cible restent modestes (de l'ordre de **[0,1 à 0,2]**) : ce sont des signaux faibles, utiles surtout en combinaison avec les variables catégorielles.

5 Préparation des données

La préparation respecte les règles suivantes :

- **aucune utilisation du jeu de test** pendant la préparation : toute transformation est apprise sur l'entraînement uniquement ;
- **valeurs manquantes** : aucune, donc ni suppression ni imputation ;
- **encodage one-hot** des 13 variables catégorielles ;
- **standardisation** des 7 variables numériques :

$$z = \frac{x - \bar{x}}{s} ; \tag{1}$$

— **découpage stratifié** : 75 % pour l'entraînement ([750] dossiers) et 25 % pour le test ([250] dossiers), avec la même proportion de mauvais risques ([0,30]) dans chaque jeu.

Ces étapes sont regroupées dans un `Pipeline` de `scikit-learn` [2], de sorte que la même chaîne de transformations est appliquée à l'entraînement, à la validation et au test.

Listing 1 – Prétraitement et découpage des données.

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.25, random_state=42, stratify=y)

preprocesseur = ColumnTransformer([
    ("num", StandardScaler(), variables_num),
    ("cat", OneHotEncoder(handle_unknown="ignore"), variables_cat),
])
```

6 Comparaison des modèles

6.1 Modèles et métriques

Quatre modèles sont comparés, du plus simple au plus complexe :

— une **référence** qui prédit toujours la classe majoritaire ;
— une **régression logistique** ;
— un **arbre de décision** de profondeur maximale 4 ;
— une **forêt aléatoire** [3] de 300 arbres.

Deux métriques sont suivies. L'**exactitude** est la part de dossiers bien classés. L'**AUC** (aire sous la courbe ROC [4]) est la probabilité qu'un mauvais payeur tiré au hasard reçoive un score de risque plus élevé qu'un bon payeur tiré au hasard : elle vaut 0,5 pour un modèle sans pouvoir de discrimination, 1 pour un modèle parfait, et ne dépend pas du seuil de décision. La comparaison s'appuie sur une validation croisée stratifiée à 5 plis sur l'ensemble d'entraînement ; le jeu de test reste de côté.

6.2 Résultats

Table 4 – Performances en validation croisée à 5 plis (ensemble d'entraînement).

Modèle	AUC moyenne	Écart-type AUC	Exactitude moyenne
Référence (classe majoritaire)	[0,500]	[0,000]	[0,700]
Régression logistique	[0,xxx]	[0,xxx]	[0,xxx]
Arbre de décision	[0,xxx]	[0,xxx]	[0,xxx]
Forêt aléatoire	[0,xxx]	[0,xxx]	[0,xxx]

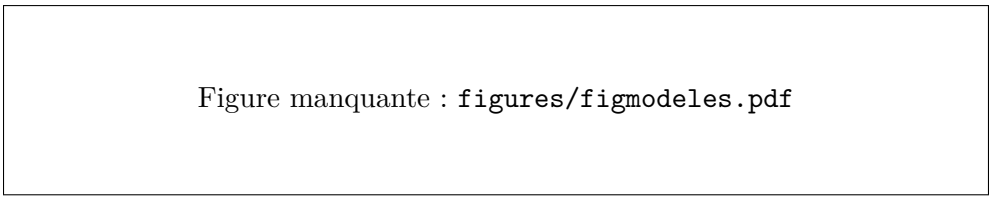


Figure 6 – AUC moyenne en validation croisée, avec écarts-types.

La référence atteint environ 70 % d'exactitude mais une AUC de exactement 0,5 : l'exactitude seule est donc trompeuse. Les modèles appris améliorent surtout l'AUC (tableau 4 et figure 6). Sur seulement 750 dossiers d'entraînement, de petits écarts d'AUC entre deux modèles ne sont pas nécessairement significatifs. Le modèle retenu, **[nom du modèle]**, présente la meilleure AUC moyenne.

7 Évaluation sur le jeu de test

Le modèle retenu est entraîné sur tout l'ensemble d'entraînement puis évalué *une seule fois* sur le jeu de test.

7.1 Matrice de confusion au seuil de 0,5

Un classifieur produit une probabilité de mauvais risque ; on refuse le dossier si cette probabilité atteint un seuil. Au seuil par défaut de 0,5, l'AUC sur le test vaut **[0,xxx]** et l'exactitude **[0,xxx]**.

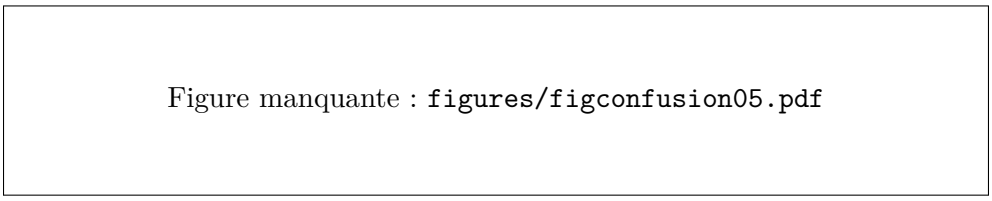


Figure 7 – Matrice de confusion au seuil 0,5 : effectifs (gauche) et proportions par situation réelle (droite).

La figure 7 montre qu'une part importante des mauvais payeurs (**[xx]** %) est acceptée par erreur, ce sont les erreurs les plus coûteuses. Le seuil de 0,5 suppose des erreurs de même coût, ce qui n'est pas le cas ici.

7.2 Courbes ROC

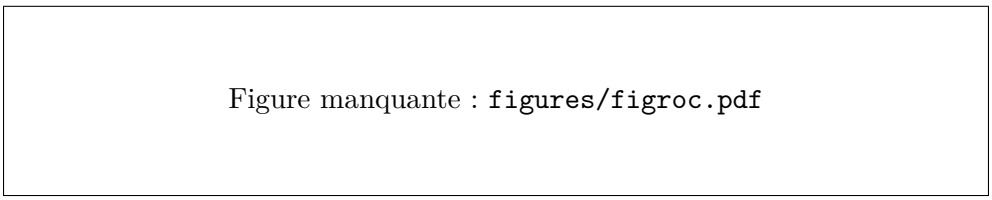


Figure 8 – Courbes ROC de tous les modèles sur le jeu de test.

La référence suit la diagonale ; les trois autres modèles s'en détachent mais leurs courbes sont proches (figure 8). Sur un jeu de test de 250 dossiers, l'ordre exact entre régression logistique et forêt aléatoire peut changer d'un découpage à l'autre : le choix du « meilleur » modèle doit rester prudent.

7.3 Courbe d'apprentissage

Figure manquante : `figures/figapprentissage.pdf`

Figure 9 – Courbe d'apprentissage du modèle retenu (AUC).

L'écart entre les courbes d'entraînement et de validation (figure 9) renseigne sur le biais et la variance. Pour une forêt aléatoire, l'AUC d'entraînement proche de 1 contre une AUC de validation autour de **[0,75–0,80]** traduit un surapprentissage ou, plus exactement, la limite de l'information contenue dans les variables. **[Commenter : la courbe de validation monte-t-elle encore ?]**

8 Choix du seuil de décision

8.1 Coût moyen et seuil optimal

Pour un seuil t, le coût moyen par dossier est

$$\text{coût}(t) = \frac{c_{\text{FN}}\,\text{FN}(t) + c_{\text{FP}}\,\text{FP}(t)}{n}, \qquad c_{\text{FN}} = 5,\ c_{\text{FP}} = 1, \tag{2}$$

où FN est le nombre de mauvais payeurs acceptés et FP le nombre de bons clients refusés. Le seuil est choisi *sans regarder le jeu de test*, à partir des probabilités prédites hors pli sur l'entraînement (`cross_val_predict`) ; le test sert uniquement à vérifier le résultat.

Si les probabilités sont bien calibrées, la théorie donne un seuil optimal

$$t^{*} = \frac{c_{\text{FP}}}{c_{\text{FP}} + c_{\text{FN}}} = \frac{1}{6} \approx 0{,}17. \tag{3}$$

Le seuil optimal observé sur l'entraînement est $t =$ **[0,xx]**.

Figure manquante : `figures/figcoutseuil.pdf`

Figure 10 – Coût moyen par dossier selon le seuil de décision.

La courbe de coût (figure 10) a une forme en cuvette : un seuil trop élevé laisse passer trop de

mauvais payeurs, un seuil trop bas refuse presque tout le monde. Le test étant de petite taille (environ 75 mauvais payeurs), sa courbe est bruitée et son minimum ne coïncide pas exactement avec celui de l'entraînement.

8.2 Comparaison des stratégies

Table 5 – Coût moyen par dossier sur le jeu de test selon la stratégie.

Stratégie	Coût moyen par dossier
Tout accepter	[0,xxx]
Tout refuser	[0,xxx]
Modèle, seuil 0,5	[0,xxx]
Modèle, seuil optimal ([0,xx])	[0,xxx]

Figure manquante : `figures/figconfusionopt.pdf`

Figure 11 – Matrice de confusion au seuil optimal.

Au seuil optimal, le rappel des mauvais risques passe de [xx] % à [xx] % et la part de bons clients refusés de [xx] % à [xx] % (figure 11). Le modèle détecte donc beaucoup plus de mauvais payeurs au prix de davantage de refus injustifiés, et le coût moyen diminue par rapport au seuil de 0,5 ainsi qu'aux deux stratégies sans modèle (tableau 5).

8.3 Analyse de sensibilité à la matrice de coûts

Le rapport de coûts de 5 pour 1 est une hypothèse. Le tableau 6 présente le seuil optimal et le coût sur le test pour plusieurs rapports $r = c_{\mathrm{FN}}/c_{\mathrm{FP}}$.

Table 6 – Sensibilité du seuil optimal au rapport de coûts.

Rapport r	Seuil optimal	Seuil théorique $1/(1+r)$	Coût moyen test
1	[0,xx]	0,500	[0,xxx]
2	[0,xx]	0,333	[0,xxx]
3	[0,xx]	0,250	[0,xxx]
5	[0,xx]	0,167	[0,xxx]
10	[0,xx]	0,091	[0,xxx]
20	[0,xx]	0,048	[0,xxx]

Figure manquante : `figures/figsensibilite.pdf`

Figure 12 – Seuil optimal observé et seuil théorique selon le rapport de coûts.

Plus accepter un mauvais payeur est coûteux, plus le seuil optimal baisse (figure 12). Le seuil observé suit globalement la courbe théorique mais s'en écarte car les probabilités du modèle ne sont pas parfaitement calibrées. Un seuil optimal ne doit jamais être présenté sans l'hypothèse de coût qui le justifie.

9 Interprétation du modèle

9.1 Importance des variables (forêt aléatoire)

Figure manquante : `figures/figimportance.pdf`

Figure 13 – Quinze variables les plus importantes de la forêt aléatoire (importance de Gini).

Les variables numériques continues (montant, âge, durée) apparaissent souvent en tête car elles offrent de nombreux points de coupure possibles : l'importance de Gini est biaisée en leur faveur. Les modalités du compte courant ressortent également (figure 13). Cette mesure dépend du modèle, peut être trompeuse en présence de variables corrélées et n'indique pas le sens de l'effet.

9.2 Coefficients de la régression logistique

Figure manquante : `figures/figcoefs.pdf`

Figure 14 – Seize effets les plus marqués de la régression logistique (rouge : augmente le risque, vert : le diminue).

Les coefficients (figure 14) indiquent le sens de l'effet : un coefficient positif augmente la probabilité de mauvais risque, un coefficient négatif la diminue. Les variables numériques étant standardisées, leurs coefficients sont comparables entre eux. Les modalités d'une même variable étant toutes présentes, les coefficients s'interprètent les uns par rapport aux autres. **[Commenter les modalités les plus marquantes.]**

9.3 Exemple de prédiction

Pour un dossier fictif (durée **[36]** mois, montant **[9 000]**, âge **[24]** ans), le modèle estime une probabilité de mauvais risque de **[0,xx]**, supérieure (resp. inférieure) au seuil de **[0,xx]** : la décision est **[REFUSER / ACCEPTER]**.

10 Discussion : éthique et limites

Éthique. Le jeu contient des variables sensibles (`personal_status`, qui mêle sexe et état civil, `age`, `foreign_worker`). Utiliser ces variables pour accepter ou refuser un crédit peut être discriminatoire, voire illégal selon les pays. Retirer ces variables ne suffit pas à garantir l'équité, d'autres variables pouvant leur servir de substitut. **[Résultat de l'expérience sans ces variables : perte d'AUC de x,xx.]**

Limites.

- seulement 1 000 dossiers, issus d'une seule banque ;
- données anciennes (années 1990) ;
- matrice de coûts supposée et non estimée à partir de pertes réelles ;
- test de petite taille (environ 250 dossiers), d'où des comparaisons entre modèles peu concluantes ;
- probabilités non parfaitement calibrées, notamment pour la forêt aléatoire.

Ces résultats illustrent une méthode : ils ne se généralisent pas tels quels à un portefeuille réel.

11 Conclusion

Ce travail a montré que la prédiction du risque de crédit relève de l'apprentissage supervisé avec des coûts asymétriques. Les principaux enseignements sont les suivants :

1. l'exactitude est trompeuse sur des classes déséquilibrées : la référence atteint 70 % sans rien apprendre ; on lui préfère l'AUC pour comparer les modèles et le coût pour décider ;
2. le meilleur modèle, **[nom]**, atteint une AUC de **[0,xx]** sur le test ;
3. le seuil de décision est un choix économique : il se choisit sur des données d'entraînement et dépend d'une hypothèse de coût qu'il faut justifier et tester ;
4. en passant du seuil 0,5 au seuil optimal, le coût moyen par dossier diminue de **[xx]** % ;
5. l'usage de variables sensibles pose un problème éthique et réglementaire.

Perspectives. Estimer la matrice de coûts à partir de données réelles, calibrer les probabilités, tester un modèle de gradient boosting (`HistGradientBoostingClassifier`) et étudier l'équité du modèle selon les groupes protégés.

A Réponses aux questions du TP

Question 1 : exactitude de 70 %

[Réponse : un modèle qui refuse tous les dossiers a une exactitude de 30 % et un coût moyen de 0,70.]

Question 2 : profondeur de l'arbre

[AUC en entraînement et en validation pour max_depth $\in \{1, 2, 4, 8, 16\}$; sous-apprentissage ou surapprentissage ?]

Question 3 : `class_weight="balanced"`

[Effet sur l'AUC et sur le seuil optimal.]

Question 4 : transformation logarithmique de `credit_amount`

[Effet sur la régression logistique et sur la forêt aléatoire.]

Question 5 : retrait des variables sensibles

[Perte de performance et discussion sur l'équité.]

Question 6 : rapport de coûts de 20

[Seuil recommandé, part de bons clients refusés, présentation à un directeur du crédit.]

Question 7 : apprentissage non supervisé

[Description d'une expérience k-means et comparaison à l'étiquette réelle (indice ARI).]

B Code utilisé

Le code complet est disponible dans le notebook `TP_apprentissage_automatique_credit_allemand.ipynb`.

Références

[1] Hofmann, H. (1994). *Statlog (German Credit Data)*. UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/144

[2] Pedregosa, F. et al. (2011). Scikit-learn : Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

[3] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.

[4] Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters*, 27(8), 861–874.